

哈尔滨工业大学深圳校区

毕业论文中期报告

题 目 基于掩星数据的气象要素反演系统设计与实现

姓 名 林逸飞

学 号 220110814

学 院 计算机科学与技术

专 业 计算机科学与技术

指 导 教 师 李旭涛

日 期 2026.3.9

目 录

1 课题主要研究内容及进度	1
1.1 课题主要研究内容	1
1.1.1 研究背景与问题提出	1
1.1.2 主要研究内容	1
1.2 进度介绍	2
2 已完成的研究工作及结果	4
2.1 数据集构建与预处理	4
2.1.1 数据来源与规模	4
2.1.2 数据处理流水线	4
2.2 模型架构设计与实现	6
2.2.1 扩散模型理论基础	6
2.2.2 增强型条件 U-Net 网络架构	8
2.2.3 条件交叉注意力机制	9
2.2.4 残差块与时间步嵌入	10
2.3 模型训练与优化	10
2.3.1 训练配置	10
2.3.2 训练过程分析	10
2.4 推理验证与性能评估	12
2.4.1 整体评估结果	12
2.4.2 气压与温度反演精度差异分析	13
3 后期拟完成的研究工作及进度安排	15
3.1 研究内容	15
3.2 进度安排	15
4 存在的困难及解决方案	17
4.1 存在的困难	17
4.2 解决方案	17
5 论文按时完成的可能性	18

1 课题主要研究内容及进度

1.1 课题主要研究内容

1.1.1 研究背景与问题提出

GNSS 无线电掩星 (Radio Occultation, RO) 技术是当前大气探测领域的核心手段之一。当全球导航卫星系统 (GNSS) 信号穿过地球大气层时, 受折射效应影响, 信号传播路径发生弯曲, 通过精确测量信号传播时的弯曲角 (Bending Angle) 廓线, 可以据此反演大气折射率、温度、气压和湿度的垂直分布, 进而为数值天气预报和气候研究提供高精度观测数据。

传统物理反演流程通常依赖两个级联模块, 先由 Abel 积分变换, 将弯曲角廓线转换为折射率廓线, 再用一维变分 (1D-Var) 同化方案, 结合背景场将折射率反演为温度、气压、湿度。然而, 上述传统路线存在固有局限: Abel 积分假设大气球对称分布, 在对流层强对流区域和大气锋面附近误差显著; 1D-Var 对背景场质量高度依赖, 且计算链路长, 误差易逐级传播累积。

在该背景下, 本课题尝试引入深度生成模型——条件扩散模型 (Conditional Diffusion Model) 直接建立弯曲角廓线到大气要素廓线的非线性映射, 以期克服传统方法的假设局限并提升反演精度。

1.1.2 主要研究内容

本课题旨在针对传统 GNSS-RO 物理反演算法中存在的误差累积与假设局限问题, 构建一套基于深度学习的端到端气象要素反演系统。核心创新点在于引入了条件扩散模型, 跳过传统的 Abel 积分与 1D-Var 等级联步骤, 直接从弯曲角廓线重构大气温度与气压的垂直精细结构。主要研究内容涵盖以下四个方面:

(1) 掩星观测数据集的构建: 基于风云三号 D 星 (FY-3D) GNOS 掩星 L2 ATP 数据, 建立多级物理质量控制流水线, 完成大规模大气廓线数据的清洗、插值与标准化。

(2) 端到端扩散反演模型的设计与实现：设计并实现了融合交叉注意力机制的增强型条件 U-Net 扩散模型架构 (EnhancedConditionalUNet1D)，实现对大气廓线垂直结构的精细重构。

(3) 对精度指标的系统性评估：在独立测试集上利用多维度定量指标 (RMSE、Bias、相关系数等) 对反演廓线进行全面定量验证，并按大气层次 (对流层、平流层、中高层) 分析误差分布特征。

(4) 系统封装与开发：将反演算法封装为模块化 Python 工具包 (ro_retrieval)，并开发相应的 Streamlit Web 前端可视化交互平台，用于在线推理和结果可视化。

1.2 进度介绍

截至 2026 年 3 月，各阶段工作完成情况如下：

数据处理阶段 (2025 年 11 月 — 2026 年 1 月)

- 完成 FY-3D GNOS L1 原始数据的调研与分析 (30,794 个文件)，明确了直接从相位数据推导弯曲角的技术难度
- 转向 L2 ATP 产品路线，完成 42,871 个 L2 ATP 文件的大规模处理
- 建立包含 7 项物理指标的质量控制体系，最终保留 37,171 条有效廓线

模型设计阶段 (2026 年 1 月 — 2026 年 2 月)

- 完成扩散模型理论调研，确定 DDPM 为核心生成框架
- 设计并实现增强型条件 U-Net 架构 (EnhancedConditionalUNet1D，参数量约 111 万)
- 引入气压对数变换预处理策略，解决大气气压跨 4 个数量级的数值分布问题

训练验证阶段 (2026 年 2 月 — 2026 年 3 月)

- 完成 Q1 全季度数据 (26,019 训练样本) 的模型训练，验证损失 0.014280
- 完成基于 DDPM 1000 步采样的推理验证，气压反演相关系数达 0.82
- 初步完成 Streamlit Web 交互平台的功能实现

后续工作将重点围绕采样算法加速、温度反演精度优化，以及毕业论文的撰写展开。

2 已完成的研究工作及结果

2.1 数据集构建与预处理

2.1.1 数据来源与规模

本研究采用风云三号 D 星 (FY-3D) GNOS 载荷的 L2 ATP (大气温度廓线) 产品作为数据来源。数据时间范围覆盖 2025 年第一季度 (1 月 1 日至 3 月 31 日), 地理覆盖范围为全球轨道观测区域。总共包含 42,871 个 NetCDF 格式文件 (约 2.2 GB), 数据变量包括弯曲角 (Opt_Bend_ang, rad)、温度 (Temp, K)、气压 (Pres, mb) 与海拔高度 (MSL_alt, km)。

前期使用 COSMIC-2 数据进行小规模训练, 由于境外网站数据下载存在困难进而转向采用国内气象卫星 FY-3D GNOS 卫星。曾尝试处理 L1 原始掩星数据 (AEG 文件), 使用几何光学方法 (Newton 迭代) 得到的弯曲角为负值 (~ -480 mrad), 与预期 ($\sim 5\text{-}20$ mrad at 30 km) 严重不符。由于从 L1 数据推导弯曲角技术难度过大, 暂时放弃, 转向直接使用官方预处理的 L2 产品, 显著降低了数据工程复杂度, 并保证了弯曲角数据的可靠性。

2.1.2 数据处理流水线

数据处理流程如下所示:




图 2.1 FY-3D GNOS L2 ATP 数据预处理流水线

步骤③“插值”中隐含了一个坐标转换环节：ATP 数据的 `Opt_Impact_parm` 字段存储的是地心距离，并非直接可用的海拔高度，需首先减去局地曲率半径（`curv`）将其换算为海拔高度（ $MSL_alt = Opt_Impact_parm - curv$ ），再以线性插值将弯曲角、温度和气压廓线统一映射至 0~60 km 等间距 301 层标准高度网格（ $\Delta h = 0.2 \text{ km}$ ）。

步骤④中采用了 $\log_{10}$ 对数非线性数值变换，主要是由于气压从地面约 1000 mb 到 60 km 高空约 0.07 mb，数值跨越 4 个数量级，若直接输入神经网络，长尾分布将导致训练过程中高层大气样本的梯度被近地面高压样本主导，从而引发高层气压梯度消失。引入对数变换后，气压数据分布特征显著改善；从图 2.2 可以看出，变换前分布严重右偏，采用 $\log_{10}$ 变换后气压分布趋于对称。该策略有效提升了扩散模型的收敛速度与训练鲁棒性。




图 2.2 气压数据对数变换前后的分布特征对比

同时与气压形成对比的是，温度变量的原始取值范围约为 150~350 K，跨度不足 2.4 倍，整体呈近似正态分布，无需对数压缩，直接进行 Z-Score 标准化即可满足网络输入要求。

2.2 模型架构设计与实现

2.2.1 扩散模型理论基础

本研究以去噪扩散概率模型（DDPM, Ho et al., 2020）为理论框架。扩散模型的核心思想是：通过一个渐进的马尔可夫加噪过程，将数据分布逐步转化为标准

高斯分布；再通过学习逆向去噪过程，从噪声中重构数据。




图 2.3 条件扩散模型工作流程图

（1）前向扩散过程（加噪）

给定原始大气廓线 x_0 ，前向过程在每一时间步 t 添加少量高斯噪声：

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t \mathbf{I})$$

其中 $\{\beta_t\}_{t=1}^T$ 为噪声调度序列（线性调度， $\beta_1 = 1 \times 10^{-4}, \beta_T = 0.02, T = 1000$ ）。

利用重参数化技巧，可以直接从 x_0 采样任意时间步 t 的加噪结果：

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I})$$

$$\bar{\alpha}_t = \prod_{s=1}^t \alpha_s, \alpha_t = 1 - \beta_t。$$

（2）反向去噪过程（条件生成）

反向过程学习从噪声逐步恢复数据：

$$p_{\theta}(x_{t-1}|x_t, c) = \mathcal{N}(x_{t-1}; \mu_{\theta}(x_t, t, c), \sigma_t^2 \mathbf{I})$$

其中均值为：

$$\mu_{\theta}(x_t, t, c) = \frac{1}{\sqrt{\alpha_t}} \left[x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(x_t, t, c) \right]$$

ϵ_{θ} 为神经网络预测的噪声， c 为条件输入（弯曲角廓线）， $\sigma_t^2 = \beta_t$ 为方差。

训练目标为最小化噪声预测误差：

$$L = E_{x_0, \epsilon, t} [||\epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \cdot x_0 + \sqrt{(1 - \bar{\alpha}_t)} \cdot \epsilon, t, c)||^2]$$

2.2.2 增强型条件 U-Net 网络架构

本课题自主设计并实现了面向一维序列数据的增强型条件扩散模型网络（EnhancedConditionalUNet1D），网络参数总量约 111 万。整体架构基于 U-Net 编解码器范式，结合条件注意力机制实现对弯曲角条件信息的多尺度融合。

网络各模块结构与参数配置如下：

表 1 增强型条件 U-Net 网络架构模块配置

模块名称	操作 / 层结构	输出形状
时间步嵌入	Sinusoidal(128) → MLP(128→128)	(B, 128)
条件编码器	Conv1d(1→64, k=3) → SiLU	(B, 64, 301)
编码器 Level-1	ResBlock(64→128)	(B, 128, 301)
	CrossAttention(128, 64)	—
	MaxPool(2)	(B, 128, 150)
编码器 Level-2	ResBlock(128→256)	(B, 256, 150)
	CrossAttention(256, 64)	—
	MaxPool(2)	(B, 256, 75)

瓶颈层	ResBlock(256→256)	(B, 256, 75)
	CrossAttention(256, 64)	—
解码器 Level-2	ConvTranspose(×2)	(B, 256, 150)
	Concat + ResBlock(512→128)	(B, 128, 150)
解码器 Level-1	ConvTranspose(×2)	(B, 128, 301)
	Concat + ResBlock(256→64)	(B, 64, 301)
输出层	Conv1d(64→2, k=1)	(B, 2, 301)

2.2.3 交叉注意力条件机制

在网络的每个尺度层引入交叉注意力机制（Cross-Attention），是本设计区别于朴素条件拼接方案的核心创新。其数学表达式为：

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Q（Query）：来自主特征图 x ，经线性投影得到，维度 (B, L, d_k)

K（Key）：来自条件编码后的弯曲角特征，维度 (B, L_c, d_k)

V（Value）：来自条件编码后的弯曲角特征，维度 (B, L_c, d_v)

引入残差连接后，最终输出为：

$$x' = x + W_{proj} \cdot Attention(Q, K, V)$$

与简单特征拼接方案相比，交叉注意力使模型能够在去噪过程中动态且自适应地聚焦于弯曲角廓线中与当前去噪状态最相关的高度区间，实现了更精细的条件信息引导。采用 4 个注意力头（Multi-Head Attention）进一步增强了特征表达的多样性。

2.2.4 残差块与时间步嵌入

残差块 (ResBlock1D) 是网络的基本计算单元, 其结构融合了 GroupNorm 归一化与 SiLU 激活函数, 同时注入时间步嵌入信息:

$$h = \text{SiLU}(\text{GroupNorm}(\text{Conv1d}(x))) + \text{MLP}(t_{emb})[:, :, \text{None}]$$

$$\text{输出} = \text{SiLU}(\text{GroupNorm}(\text{Conv1d}(h))) + \text{shortcut}(x)$$

时间步 t 经正弦位置编码 (Sinusoidal Positional Encoding) 后, 通过 MLP 投影为 128 维向量并注入每个残差块, 使模型能够感知当前处于扩散过程的哪一阶段, 从而自适应调整去噪策略。

2.3 模型训练与优化

2.3.1 训练配置

模型训练部署于高性能计算平台 (Tesla V100-PCIE-32GB GPU)。详细训练配置如下:

优化器: Adam, 初始学习率 1×10^{-4}

批量大小: 64

最大训练轮次: 100 Epoch

正则化策略: 梯度裁剪 ($\text{max_norm}=1.0$) + 早停机制 ($\text{patience}=20$)

损失函数: 均方误差 (MSE), 作用于噪声预测残差

2.3.2 训练过程分析




图 2.4 增强型条件 U-Net 扩散模型训练与验证损失收敛曲线

训练过程呈现出清晰的三阶段收敛规律：

- 快速下降阶段（Epoch 1-30）：验证损失由初始值迅速下降至约 0.022，模型快速学习大气廓线的整体分布特征与主要垂直趋势。
- 精细优化阶段（Epoch 30-62）：损失曲线进入平台区，呈现缓慢而持续的下降，模型逐步捕捉廓线的局部细节特征，如对流层顶附近的温度梯度变化。
- 最优收敛点（Epoch 62/100）：验证损失在第 62 个 Epoch 首次达到最低值 0.014280。此后持续至第 100 个 Epoch 未再出现显著下降，早停机制未触发，说明模型在当前数据规模下已基本达到收敛。

为验证数据量对模型泛化能力的影响，本研究对比了单月数据（2025 年 1 月）与 Q1 全季度数据（2025 年 1-3 月）两组实验。结果如下：

表 2 不同数据规模下性能指标的对比

对比维度	单月模型	Q1 季度模型	相对提升
训练样本数	9,244	26,019	+181.6%
最优验证损失	0.016882	0.014280	-15.4%
气压 CC	0.75	0.8185	+9.1%

气压 RMSE	146.82 mb	123.44 mb	-15.9%
温度 CC	0.23	0.2483	+8.0%

实验结果表明，将训练数据从单月扩展至全季度（样本量增加约 2.8 倍）后，各项指标均有显著提升。这说明覆盖更丰富季节性气象模态的训练数据，有效增强了模型对复杂大气状态的泛化能力。

2.4 推理验证与性能评估

2.4.1 整体评估结果




图 2.4 测试集气压反演值与真实标签散点对比图

在包含 5,577 个样本的独立测试集上，采用 DDPM 标准 1000 步采样策略进行系统性验证。整体评估结果如下：

表 3 模型推理性能整体定量评估结果

变量	RMSE	Bias	相关系数
温度	26.26 K	-1.89 K	0.2483
气压	123.44 mb	-35.21 mb	0.8185




图 2.5 典型掩星事件温度与气压反演廓线精细重构示例

大气垂直结构在不同层次具有显著不同的物理特征，分层分析误差对于理解模型的反演机理至关重要。按标准大气分层（对流层：0-12 km，平流层：12-30 km，中高层：30-60 km）对测试结果进行统计，主要规律如下：

- 近地面层（0-5 km）：气压梯度最大，弯曲角信号最强，气压反演 RMSE 最低，相关系数最高。温度因受水汽扰动影响，误差相对较大。
- 对流层主体（5-12 km）：温度廓线受水汽垂直分布影响，温湿耦合效应显著。在缺少湿度标签联合约束的情况下，模型从弯曲角中解耦纯温度信号的能力受限，是温度 RMSE 偏高的主要原因。
- 平流层（12-30 km）：水汽含量趋近于零，温湿耦合问题消失。但平流层温度垂直梯度较小，弯曲角信号随高度指数衰减，有效观测信息量减少，反演主要依赖模型学习的统计规律。
- 中高层（30-60 km）：弯曲角信号极弱，接近观测噪声水平，反演误差随高度增加而增大。

2.4.2 气压与温度反演精度差异分析

（1）气压反演表现优异（CC=0.82）

从大气物理学角度分析，弯曲角与大气折射率 N 之间存在近似线性关系（ $N = 77.6 \frac{P}{T} + 3.73 \times 10^5 \frac{e}{T^2}$ ），其中气压项主导了折射率的整体量级。在流体静力学平衡条件下，气压与大气密度强耦合，而弯曲角本质上反映的是密度的垂直

积分效应。因此，从弯曲角提取气压信息的物理路径较为直接，模型成功提取了这一潜在映射机制。

（2）温度反演精度不佳（CC=0.25）

温度属于折射率公式中的衍生变量，在对流层中低层，水汽项（ $3.73 \times 10^5 \frac{e}{T^2}$ ）对折射率的贡献不可忽视，导致弯曲角中的温度信号与水汽信号深度耦合，形成经典的"温湿模糊"问题（moisture-temperature ambiguity）。在本研究当前阶段，数据集为干大气廓线（ATP）数据，训练标签仅包含温度和气压，不含湿度信息，模型难以在无外部约束的情况下完全分离这两种贡献，这是温度反演精度受限的核心原因，后续将添加湿大气廓线（WAP）作为数据集继续开展训练。

（3）效率瓶颈

当前 DDPM 采用完整的 1000 步马尔可夫链去噪，处理全部 5,577 个测试样本耗时约 36 分钟（单样本平均 0.39 秒），推理速度无法满足实时业务化应用的需求，亟需采样加速方案。

3 后期拟完成的研究工作及进度安排

3.1 研究内容

(1) 湿大气廓线数据集的扩充与融合：在现有 FY-3D GNOS L2 ATP（干大气廓线）数据集的基础上，引入湿大气廓线（Wet Atmospheric Profile, WAP）产品，将模型输出通道由当前的 2 通道（温度、气压）扩展为 3 通道（温度、气压、湿度），构建完整的干湿融合大气廓线数据集。

(2) 基于隐式采样的推理加速优化：针对 DDPM 推理耗时过长的问题，通过引入去噪扩散隐式模型（DDIM）或高阶 ODE 求解器（DPM-Solver），在保证反演精度的前提下将采样步数压缩至 100 步以内，目标推理速度提升 10 倍以上。

(3) 物理先验约束下的温度精度攻关：探索将大气温度递减率、流体静力学方程等先验知识转化为正则化损失项，或联合湿度要素进行多任务协同学习，以期将温度反演相关系数提升至 0.4 以上。

(4) 系统级封装与可视化平台落地：完成 ro_retrieval 算法库的标准化发布，并利用 Streamlit 框架搭建响应式 Web 可视化分析平台，打通数据解析、在线推理与指标可视化的全链路。

(5) 毕业论文撰写与学术总结：系统性总结研究方法、消融实验与对比实验结果，规范撰写毕业论文，完善答辩评审材料。

3.2 进度安排

- 2026 年 3 月上旬：攻克 DDIM 加速采样中的数值不稳定问题，完成推理引擎的性能调优。

- 2026 年 3 月中旬：实现系统工程化封装，完成 Streamlit 交互式 Web 界面的部署与测试。

- 2026 年 3 月下旬 - 4 月上旬：启动毕业论文初稿撰写，重点完善方法论推导与消融实验分析。

- 2026 年 4 月中旬：根据指导教师反馈进行论文多轮润色与查重，定稿并制作

答辩展示材料。

- 2026 年 4 月下旬：进行项目演示筹备并参加最终毕业答辩。

4 存在的困难及解决方案

4.1 存在的困难

(1) 湿大气廓线数据的获取与时空匹配: WAP 数据与当前使用的 ATP 数据来源不同,两者在时间分辨率、空间覆盖和坐标系统上存在差异,需要进行精细的时空配准。FY-3D GNOS 的湿大气产品观测密度相对有限,有效配对廓线数量可能显著低于 ATP 单独使用时的规模,影响后续训练的数据充足性。

(2) 非马尔可夫加速采样(DDIM)轨迹崩溃:尝试应用 DDIM 将采样步数由 1000 步激进削减至 50 步时,输出结果出现灾难性发散(相关系数趋零, RMSE 极度膨胀)。初步技术分析表明,由于大气廓线包含严密的流体静力学约束,步长过大可能导致 ODE 求解器在反向积分过程中偏离真实的数据流形(Data Manifold),加之噪声调度(Noise Schedule)未针对大步长进行重标定,引发了累积截断误差。

(3) 在掩星物理学中,对流层中低层折射率由温度项与水汽项共同主导,二者深度耦合。即便引入 WAP 湿度标签,模型在有限样本条件下能否从单一弯曲角廓线中有效分离温湿贡献,仍存在不确定性,可能需要引入外部约束或多源辅助数据。

(4) 工业级应用的实时性制约:当前依赖完整 DDPM 链的生成过程耗时偏高,距离掩星数据同化系统对高时效性的要求仍有差距。

4.2 解决方案

(1) 湿大气廓线数据的获取与融合策略:优先从国家卫星气象中心(NSMC)公开数据接口获取 FY-3D GNOS WAP 产品;若官方产品可用性受限,则以 ERA5 再分析数据的比湿(specific humidity)廓线作为湿度标签替代方案,按掩星事件的经纬度和时间进行最近邻时空插值匹配。时空配准误差控制在水平 50 km、时间 1 小时以内,以保证物理一致性。

(2) 针对 DDIM 崩溃采取渐进式调优策略:放弃一步压缩至 50 步的激进

策略，采用渐进降步实验（1000→500→200→100 步），逐步定位精度崩溃的临界步数区间；同步引入 DPM-Solver 高阶求解器，利用高阶泰勒展开降低截断误差；并对噪声调度器进行重标定，使其适配大步长加速采样的积分精度需求。

（3）温湿联合反演与物理约束正则化：引入 WAP 湿度标签后，将温度、气压、湿度纳入统一的多任务学习框架（Multi-Task Learning），共享编码器特征，任务间梯度通过不确定性加权（Uncertainty Weighting）动态平衡；同时在损失函数中附加流体静力学方程约束项（ $\partial P / \partial z = -\rho g$ ），以物理规律抑制廓线预测中的非物理振荡。

（4）推理引擎加速与轻量化：在代码层面实现张量化（Tensorized）的批量并行推理（Batch Inference），充分压榨 GPU 的流处理器算力。若算法层加速仍不理想，考虑运用知识蒸馏（Knowledge Distillation）技术压缩模型体积。

5 论文按时完成的可能性

目前项目核心工作已基本完成：数据流水线、模型训练和 DDPM 基线推理均已跑通，气压反演相关系数达 0.82，说明扩散模型用于掩星反演这条路线是可行的。剩余工作（DDIM 加速、温度精度改进、系统封装、论文撰写）均在可预期范围内有序推进。